

FINAL PROJECT REPORT · 2026

期末大作业汇报

电影推荐系统 · 评分预测的优化与深化
+ 电影类型预测的深化

蒋名仪 | 2500010771

期末新增任务一览

OVERVIEW			
编号	任务	方法	标签
2.3	海报视觉特征增强评分预测	ResNet-50 → PCA → VisSVD	必做1a
2.4	LLM 背景知识增强评分预测	DeepSeek + MiniLM → LightGBM 残差	必做1b
2.5	传统 SVD 与新方案对比 + Stacking	4 专家 × 4 场景 + Ridge 元学习器	必做1c
2.6	SVD 异常用户分析 + 画像 + 定向优化	残差閾值 → KMeans → 专家切换	必做2a
2.7	复杂模型：多专家 MOE	Gating MLP + softmax 动态路由	可选3
3.1	MiniLM + 微调层预测电影类型	frozen MiniLM → Linear / MLP 头	必做T2
3.2	主题电影类 × 年龄相关性	LDA 主题 → 年龄区分度	可选B1
3.3	LLM Embedding + 微调预测类型	text-embedding-3-small → MLP-256	可选B2

期中基线（仅作对照）：M2 加性偏置 $\hat{r} = \mu + b_u + b_i$ ；M3 FunkSVD 加潜因子 $\mathbf{p}_u^T \mathbf{q}_i$ ；M2+ 叠加类型/人口学偏置。

核心问题

协同过滤只看"谁给哪部电影打了几分"，完全忽略电影的视觉风格。然而海报的色调、构图、人物排布是稳定的风格信号。

对于几乎没人评分的冷门电影，协同过滤的潜因子 $\mathbf{q}_i$ 根本学不到——评分太少。但海报特征始终可用。

解决思路

把海报视觉向量 $\tilde{\mathbf{v}}_i$ 注入 SVD：即使 $\mathbf{q}_i$ 学不动， $W\tilde{\mathbf{v}}_i$ 仍提供非零信号，缓解冷启动。

M6 VISSVD 公式

$$\hat{r}_{ui} = \mu + b_u + b_i + \mathbf{p}_u^T(\mathbf{q}_i + W\tilde{\mathbf{v}}_i)$$

$\tilde{\mathbf{v}}_i$ ：海报经 ResNet-50 提取 512 维特征后 PCA 降至 64 维

W ：可学习的视觉→潜空间投影矩阵

$\mathbf{q}_i$ ：自由潜因子（协同）；冷门电影 $\mathbf{q}_i \approx 0$ 时 $W\tilde{\mathbf{v}}_i$ 兜底

实现流程

- Step 1 ResNet-50 抽 512 维海报特征 → 缓存
- Step 2 PCA 降到 64 维去噪；余弦相似度建 Visual Item-KNN (M5)
- Step 3 将 $\tilde{\mathbf{v}}_i$ 注入 FunkSVD，联合训练 W (M6)
- Step 4 按电影流行度分桶，单独考察冷门电影增益

2.3 视觉特征结果：冷门电影增益最明显

全量开放测试集 MSE

M3 FunkSVD = 0.7144（训练充分的基座）

M5 Visual-KNN = 1.3373（纯视觉，无协同，较差）

M6 VisSVD = 0.7184（协同 + 视觉）

为什么全量 MSE 提升不大？

视觉 side-info 只在冷门电影（评分 < 100 条）上 RMSE 降低明显。但冷门电影仅占测试集 0.6%，加权到全量后被严重稀释。

热门电影的协同信号已经足够强，额外的视觉信号边际贡献被稀释。

结论

→ 典型的 "side-info 只在稀疏区域有效"

这是结构性的，不是方法写错了。视觉特征的价值在于缓解冷启动，而非提升全量精度。




Fig 2.3 - 按电影流行度分桶的 RMSE 对比

核心问题

ratings 表只有行为信号——谁打了几分。缺少电影的"世界知识": 口碑评价、主题风格、奖项、情绪基调。

这些信息恰好存在于 LLM 的训练语料和文本语义中。

双路径设计

路径 A — 在线 LLM: DeepSeek API 返回 online_rating / themes / award_level / sentiment, 结构化数值特征。

路径 B — 本地 MiniLM: 把 name + intro + 导演 + 主演编码成 384 维语义向量, 作为 API 不可用时的 fallback。

M7 内容残差模型公式

$$\hat{r}_{ui} = \hat{r}_{ui}^{M2+} + g_{\theta}(c_i, u_u)$$

c_i : 电影内容特征 (LLM 知识 $\oplus$ MiniLM 句向量)

u_u : 用户人口学特征 (年龄、性别、职业)

g_{θ} : LightGBM 学习"基线 M2+ 没拟合到的残差"

LightGBM 自动捕捉交叉项 (如"学生 $\times$ Comedy")

为什么用残差而非直接预测?

协同基线 M2+ 已经拟合了大部分评分模式。内容特征只需要学基线遗漏的部分, 避免从头拟合, 降低过拟合风险。

2.4 LLM 内容残差：结果与启示

关键结果

M7 内容残差 (LightGBM) 开放 MSE = 0.8149

对比：M3 FunkSVD = 0.7144（训练充分的纯协同）

特征重要性分析

$\hat{r}^{M2+}$ （协同基线预测值）占绝对主导地位。occ / age / 内容向量 c^* 有一定补充贡献，但远不如协同信号。

为什么 M7 没有超过 M3？

基座 M3 训练充分后 MSE = 0.714，已经从行为信号中提取了绝大部分可预测信息。外部内容知识是补充而非主力。

这说明在该数据集上，用户评分行为本身已经足够强——LLM 知识的价值更多在冷启动和内容理解场景。




Fig 2.4 - LightGBM 特征重要性排序

2.5 Stacking：如何协同四个专家？

STACKING

核心问题

四个专家（M3 协同、M2+ 偏置、M6 视觉、M7 内容）各有所长，但单看全量 MSE 看不出差异——因为在不同场景（冷门/热门/稀有 genre）下优势不同。

解决思路

Stacking 元学习：用一个 Ridge 回归器学一组全局权重 α ，把四个专家的预测线性组合。

STACKING 公式

$$\hat{r}^{\text{Stack}} = \alpha_0 + \alpha^T \mathbf{z}$$
$$\mathbf{z} = (\hat{r}^{M3}, \hat{r}^{M2+}, \hat{r}^{M6}, \hat{r}^{M7})$$

$$\alpha = \arg \min_{\alpha} \|\mathbf{y} - \alpha_0 \mathbf{1} - Z\alpha\|^2 + \lambda \|\alpha\|^2$$

$\mathbf{z}$ ：四模型预测拼成的 4 维向量； α ：Ridge 学到的权重

防泄漏：用训练集再切一折 meta-val 学 α ，不碰测试集

场景分桶实测（基座训练充分后）

冷门电影 $\rightarrow$ M6 VisSVD 略优（视觉兜底）

稀有 genre / 热门头部 $\rightarrow$ M3 最优（协同最强）

M2+ / M7（人口学/内容）全场景被压制

为什么外部信息被压制？

基座 M3 训练充分后，行为协同信号已经足够强。人口学和内容特征提供的信息与协同高度冗余（M3 与 M6 预测相关性 0.98），难以带来额外增益。

2.5 Stacking 结果：强相关专家集成增益有限

关键数值

M3 FunkSVD（单模型） = 0.7144

Stacking（4 专家线性组合） = 0.7386

SegmentBlend（分场景最优混合） = 0.7132

STACKING 权重揭示了什么？

Ridge 学到的权重：M3 = 1.86, M2+ = -0.849, M6 = -0.277, M7 = 0.282

M3 权重远超其他 → 元学习器几乎只信 M3。M2+ 甚至是负权重（被 M3 压制后，反而引入噪声）。

结论

全局 Stacking 反而略差于 M3 单模型

原因：当专家之间高度相关时（相关性 0.98），线性组合容易 meta 过拟合。集成要有真增益，专家必须“错在不同地方”。

→ 见反思页：集成要“去相关”才有效




Fig 2.5 - 4 专家 × 4 场景 MSE 对比

2.6 ① 异常用户：如何定义？画像是什么？

ANOMALY PROFILE

异常定义（残差阈值法）

$$e_{ui} = r_{ui} - \hat{r}_{ui}^{M3}, \quad \text{异常样本} \Leftrightarrow |e_{ui}| > 1.5$$

异常用户 = 评分数 ≥ 30 的用户中, $\overline{|e_u|}$ 排名前 5%

e_{ui} : M3 预测残差; $\overline{|e_u|}$: 用户级平均绝对残差

异常样本 $\approx 4.57\%$; 异常用户 = 260 人

真实画像 (NOTEBOOK 结论)

职业: 学生 + 教育工作者合计占 32% (全体仅 25%) $\rightarrow$ 明显偏高

年龄: 横跨 18-24 / 25-34 / 35-44, 并非单一年龄段

题材: Comedy 各簇均居首, Romance 在爱情片簇突出

为什么这些人“异常”?

评分习惯个性化 (过严/过松/口味偏窄), 全局 M3 难以拟合 $\rightarrow$ 残差被放大。




Fig 2.6a - 职业/年龄/题材分布 & 残差直方图

2.6 ② 聚类画像 + 切换专家：谁该信谁？

CLUSTER × EXPERT

KMEANS 聚类（行为特征）

特征：评分均值/方差、高分%/低分%、题材熵、偏好年代

4 个异常用户簇：

C0 / C1 中庸高残差型 — 均分中等，评分模式多样

C2 低分严苛型 — 均分低，低分比例高

C3 高分宽松型 — 均分高，高分比例高

核心问题：异常用户上谁最准？

M3 异常 MSE = 1.346 | M6 VisSVD = 1.342（最优）

M2+ = 1.510 | M7 LLM = 1.490（远差于 M3/M6）

启示

异常用户误差 $\approx$ 正常用户的 2 倍

M2+ / M7（人口学/内容）反而更差 $\rightarrow$ 异常源于个人潜在口味，而非缺人口学/内容特征。潜因子 + 视觉才是最贴合的信号。




Fig 2.6b - 聚类可视化 & 各专家异常 MSE

2.6 ③ 异常用户定向优化：效果与反思

TARGETED CALIBRATION

思路：不动正常用户，只校准异常用户

方法一：重估用户偏置

$$b_u^* = \frac{\sum_{i \in I(u)} (r_{ui} - \mu - b_i)}{|I(u)| + \lambda_u}$$

固定 b_i ，只用用户自己的残差收缩估计 b_u^* ，防止对极端用户过拟合

方法二：簇专属专家融合

$$\hat{r}_{ui} = \sum_k w_{g(u),k} \hat{r}_{ui}^{(k)}, \quad \mathbf{w}_g = \text{softmax}\left(-\frac{\text{MSE}_g}{\tau}\right)$$

$g(u)$ ：用户所属簇；按各专家在该簇的误差学权重，误差越小权重越大

结果

异常用户 MSE: 1.342 $\rightarrow$ 1.344 (基本持平)

基座训练充分后，异常用户误差已是不可约噪声，后处理无效。价值在于“识别 + 分流”，而非强行校准。




Fig 2.6c - 异常用户定向优化效果

核心问题

Stacking 给所有样本同一组权重。但 2.5/2.6 已经显示: 不同场景、不同用户, 该信的专家不同。

能不能让模型自动看当前样本属于哪种场景, 动态分配权重?

MOE 公式

$$\hat{r}_{ui} = \sum_k \pi_k(\mathbf{x}_{ui}; \theta) \hat{r}_{ui}^{(k)}, \quad \sum_k \pi_k = 1$$

$$\boldsymbol{\pi} = \text{softmax}(W_2 \text{ReLU}(W_1 \mathbf{x} + b_1) + b_2)$$

π_k : 第 k 个专家的 softmax 权重 (样本级动态)

$\mathbf{x}_{ui}$: 上下文特征; 专家参数固定, 只训练 gating 网络

与 STACKING 的关键区别

Stacking = 全局固定权重 $\boldsymbol{\alpha}$ (一组权重用于所有样本)

MOE = 按样本动态权重 $\boldsymbol{\pi}(\mathbf{x})$ (软路由)

ROUTER 输入特征

用户评分数 / 均值 / 方差

电影热度、冷启动标志、稀有 genre 标志

异常用户簇 one-hot

→ 让路由“知道”当前样本属于哪种场景, 自动选最合适的专家。

2.7 MOE 结果：为什么 $\text{MOE} \approx \text{M3}$?

关键结果

MOE 开放 $\text{MSE} = 0.7143$

(4 experts: M3 / M2+ / M6 / M7)

对比 M3 = 0.7144 — 几乎相同

路由权重分析

M3/M6 训练充分后全面占优，**router 收敛到几乎只用 M3**（权重 ≈ 0.99 ）。

这不是 MOE 的失败——恰恰是 MOE 的正确行为：当某专家在所有场景都更优时，理性的路由器自动归一到它。

结论

MOE 的动态路由比 Stacking 的固定权重更合理

但在“一家独大”的专家格局下，动态路由没有发挥空间。要让 MOE 有真增益，需要专家之间能力更互补。




Fig 2.7 - MOE 各场景路由权重分布

3.1 MiniLM 语义替代 TF-IDF 预测电影类型

GENRE PREDICTION

核心问题

期中用 TF-IDF 词袋做类型预测，丢了词序与上下文语义（如反讽、隐喻）。改用预训练 transformer 的语义表示。

为什么用冻结 ENCODER + 浅头？

数据仅 ~2k 部电影。全微调 transformer 容易过拟合。冻结 MiniLM-L6（22M 参数，6 层）抽 384 维句向量，只训练一个浅分类头，参数量少且训练快。

公式

$$\mathbf{z}_i = \text{MiniLM}(\text{intro}_i) \in \mathbb{R}^{384}$$

$$F \text{（线性头）} : \hat{y} = \sigma(W\mathbf{z}_i + b)$$

$$G \text{（MLP 头）} : \hat{y} = \sigma(W_2 \text{ReLU}(W_1\mathbf{z}_i) + b)$$

σ : sigmoid（逐 genre 独立输出 0/1）

损失函数：BCEWithLogitsLoss（多标签二分类）

评测指标（多标签）

Hamming loss · Jaccard · F1-macro · F1-samples · Subset accuracy

3.1 MiniLM 结果：语义表示稳定提升

横向对比

B LR-OVR (TF-IDF): F1-samples = 0.4751

F MiniLM + Linear 头: F1-samples = 0.5054

G MiniLM + MLP 头: F1-samples = 0.5599

逐级提升的原因

TF-IDF → MiniLM: 从关键词匹配升级到语义理解。"a man struggles with his past" 在 TF-IDF 里只有词频, 在 MiniLM 里编码了"挣扎/过去/内心冲突"的语义。

Linear → MLP: genre 之间有非线性关系 (如 Action + Sci-Fi 常共现), MLP 能捕捉这些交互模式, 线性头不行。

结论

MLP 头 > 线性头 > TF-IDF 基线

语义表示 + 适当的分类头 = 小数据多标签的最佳实践。




Fig 3.1 - 各方法多标签 F1 对比

3.2 LDA 主题 × 年龄：哪些偏好随年龄变化？

TOPIC × AGE

核心问题

genre 是离散标签 (Action / Drama / ...)，但语义主题更细粒度。用 LDA 从电影简介中抽取"语义主题"，研究哪些主题偏好随年龄显著变化。

公式

$$\pi_d \in \Delta^{K-1} \quad (\text{电影 } d \text{ 的 LDA 主题分布})$$

$$\text{discrim}_k = \frac{1}{|A|} \sum_a (\bar{r}_{ka} - \bar{r}_k)^2$$

$\bar{r}_{ka}$ ：年龄段 a 对主题 k 的加权平均评分

按 discrim 挑最具年龄区分度的 top-3 主题

TOP 年龄敏感主题

t1: love, man, falls, woman, young (爱情/青春)

t2: war, world, ii, group, evil (战争/历史)

t5: new, life, york (都市/生活)

结论

各主题评分都随年龄升高 → 年长用户打分更宽容

战争/历史主题的年龄梯度最陡，都市/爱情相对平缓。




Fig 3.2 - 主题 × 年龄段 评分热图

3.3 LLM 高维嵌入：进一步提升类型预测

LLM EMBEDDING

核心问题

3.1 用 MiniLM（384 维），是通用小模型。能否换成大模型句嵌入（1536 维），利用更广泛的语料和更丰富的语义？

公式

$$\mathbf{z}_i^{\text{LLM}} = \text{Embed_API}(\text{intro}_i) \in \mathbb{R}^{1536}$$

$$H : \hat{y} = \sigma(\text{MLP}_{256}(\mathbf{z}_i^{\text{LLM}}))$$

1536 维 → 256 隐层 MLP → sigmoid 多标签输出

维度高 → Dropout = 0.4 + weight decay 抑制过拟合

结果

G MiniLM+MLP: F1-samples = 0.5599

H LLM-emb+MLP: F1-samples = 0.6347

结论

高维语义嵌入 + 适当正则 → 冻结方案最优

但嵌入是“冻结”的——能否让模型针对电影分类任务端到端学习？ → 3.4 BERT 微调




Fig 3.3 - 全部方法类型预测指标对比

3.4 BERT 端到端微调：让语义表示针对任务学习

FINE-TUNING

核心思路

之前的方案（MiniLM / LLM-emb）都是冻结嵌入 + 训练浅头——预训练模型不了解“电影类型”这个任务。

端到端微调：让 DistilBERT 的 6700 万参数全部 针对电影分类任务更新。

公式

$$I : \hat{y} = \sigma(W_c \cdot \text{ReLU}(W_p \cdot \text{BERT}_{\theta}(\text{intro}_i)_{[\text{CLS}]}))$$

θ 端到端更新，lr = 2e-5, 4 epochs, CPU 训练 ~95 min

结果对比

H LLM-emb+MLP (冻结 1536 维): F1 = 0.6347

I BERT-finetune (端到端 67M): F1 = 0.6160

分析

DistilBERT（67M 参数，768 维）微调 4 epoch 已接近冻结 LLM 1536 维方案。CPU 限制了训练轮数；更多 epoch 或用 GPU 可进一步提升。

端到端微调验证了“让模型针对下游任务学习”的价值。




Fig 3.4 - 加入 BERT 微调后全部方法对比

最大杠杆：把基座 SVD 训练充分

发现了什么？

原始 FunkSVD 实现每 epoch 仅采样 ~32% 数据进行梯度更新 → 严重欠拟合。

改为全量向量化 mini-batch SGD，纯 CPU，FunkSVD $\approx$ 35s，VisSVD $\approx$ 3min。

效果

M3 MSE: 0.823 → 0.714 ↓ 13.2%

异常用户 MSE: 1.69 → 1.34

这一步的提升，远超海报/LLM/Stacking/MOE 全部叠加 (~1%) 之总和。

为什么这才是关键？

所有 side-information 只在协同信号不足时有用。如果基座本身就没训练好，side-info 看起来"有效"——实际上只是在弥补基座的欠拟合。

一旦基座训练充分，side-info 的边际贡献几乎消失。

核心 TAKEAWAY

主瓶颈是基座是否训练充分，不是缺信息

根因一：新增信息与协同高度冗余

M3 与 M6 预测相关性 **0.98**。冷门电影仅占测试集 0.6%，冷用户 0%——side-info 只在极少数稀疏样本有用，加权到全量后被严重稀释。

根因二：误差已接近不可约噪声地板

同一用户对同类电影评分波动大。M3 = 0.714 已逼近该数据的可预测性极限。

根因三：集成 / 后处理天然增益小

M2+/M7 全面被 M3 压制；Stacking = 0.7386 反而 > M3（meta 过拟合）；异常后处理持平。

这些是**结构性原因**：行为信号足够强、基座充分训练后，外部信息边际收益天然很小。

① 升级矩阵分解模型

SVD++（纳入隐式反馈）、timeSVD++（偏置随时间漂移）。当前 FunkSVD 只用了显式评分。

② 联合建模而非“残差外挂”

FM / DeepFM 把潜因子+人口学+内容放进一个模型，直接学交叉项。

③ 集成要“去相关”

加入 user/item-KNN 等误差结构不同的模型，集成才有真增益。

④ 换评测目标

推荐真正在意排序（NDCG / Recall@K），side-info 对排序帮助远大于逐点 MSE。

评分预测 (PART 2) 全量 MSE

M3 FunkSVD (训练充分) **0.7144** ← 最佳

M6 VisSVD 0.7184 · M7 LLM 0.8149

Stacking 0.739 · SegBlend 0.713 · MOE 0.714

类型预测 (PART 3)

最佳 H (LLM 1536 维 + MLP-256) F1 = 0.6347


I BERT 微调 (端到端 67M) F1 = 0.6160, 验证微调路线

异常用户

260 人, 学生/教育工作者偏多, 应"识别+分流"

核心 TAKEAWAYS

- ① Side-info 只在稀疏区域有价值, 全量提升有限是**结构性的**
- ② 异常用户应"识别+分流到合适专家"
- ③ MOE 动态路由比 Stacking 更合理
- ④ 语义嵌入 + 浅头 = 小数据最优; 端到端微调是进一步提升方向
- ⑤ **最大杠杆 = 训练充分的基座 SVD (↓13%)**



谢谢

蒋名仪

2500010771